



**Albert Kistowski**

Analiza determinantów opóźnień w transporcie lotniczym z wykorzystaniem Uporządkowanego Modelu Logitowego

Analysis of air transport delay determinants using the Ordered Logit Model

**Praca licencjacka**

Promotor: dr W. Roszka

Pracę przyjęto dnia: .....

Kierunek: Informatyka i Ekonometria

Poznań 2026

# Rozdział 1

## Teoretyczne i metodologiczne aspekty analizy opóźnień w transporcie lotniczym

### 1 Istota i klasyfikacja opóźnień lotniczych

Transport lotniczy stanowi jeden z absolutnych fundamentów współczesnej, zglobalizowanej gospodarki, zapewniając bezprecedensową mobilność kapitału ludzkiego oraz ułatwiając zintegrowaną, międzynarodową wymianę handlową w czasie rzeczywistym. W dobie gospodarki opartej na modelu *just-in-time*, sprawność łańcuchów dostaw, operacje logistyczne korporacji transnarodowych oraz mobilność kadry zarządczej zależą bezpośrednio od przewidywalności operacji lotniczych. Sektor ten generuje znaczący wkład w globalny produkt krajowy brutto, wykazując przy tym niezwykle silny efekt mnożnikowy – każda jednostka wartości dodanej wytworzona bezpośrednio w lotnictwie generuje dodatkowe zyski w sektorze turystycznym, handlowym, usługach wysokospecjalistycznych oraz infrastrukturze lokalnej (Federal Aviation Administration, 2022).

Jednocześnie, lotnictwo cywilne to system o niezwykle wysokim stopniu złożoności operacyjnej (tzw. system socjotechniczny), w którym koordynacja tysięcy maszyn, załóg lotniczych, służb kontroli ruchu oraz personelu obsługi naziemnej musi odbywać się w sposób ciągły, pod rygorem ekstremalnych i bezwzględnych norm bezpieczeństwa. Ta wielowymiarowa współzależność sprawia, że jest to środowisko wysoce wrażliwe na wszelkiego rodzaju zakłócenia, których ostatecznym, mierzalnym i najbardziej odczuwalnym symptomem są opóźnienia lotów.

W literaturze przedmiotu opóźnienie definiuje się najczęściej jako różnicę pomiędzy planowanym czasem rozkładowym a rzeczywistym czasem realizacji danej operacji lotniczej. Wraz z dynamicznym rozwojem technologii i cyfryzacją lotnictwa, głębokiej ewolucji uległ sposób precyzyjnego pomiaru tego zjawiska. Współcześnie dane o punktualności nie są już rejestrowane w oparciu o subiektywne raporty załóg, lecz są generowane automatycznie poprzez standard OOOI (*Out, Off, On, In*), wspierany przez pokładowe systemy teleinformatyczne (takie jak ACARS - *Aircraft Communications Addressing and Reporting System*). System ten z niezwykle precyzją

rozdziela cztery krytyczne momenty każdego rejsu:

- **Out-of-gate (Czas odwołania):** moment zwolnienia hamulców postojowych i odepchnięcia statku powietrznego od rękawa lub stanowiska postojowego (tzw. *off-block time*);
- **Off-ground (Czas startu):** fizyczna chwila oderwania kół maszyny od nawierzchni pasa startowego;
- **On-ground (Czas lądowania):** moment fizycznego dotknięcia pasa startowego przez podwozie samolotu na lotnisku docelowym;
- **In-gate (Czas dokowania):** chwila całkowitego zatrzymania maszyny i zaciągnięcia hamulców na stanowisku docelowym (*in-block time*).

Dzięki powyższej kategoryzacji badacze oraz analitycy rynkowi mogą wyodrębnić dwie główne płaszczyzny pomiaru: opóźnienie wylotu (*departure delay*) oraz opóźnienie przylotu (*arrival delay*) (Doganis, 2010). Z perspektywy konsumenta (pasażera) kluczowe jest dotarcie do miejsca docelowego zgodnie z planem, dlatego linie lotnicze w swoich materiałach marketingowych skupiają się na punktualności przylotów. Jednakże z punktu widzenia efektywności zarządzania portem lotniczym, alokacji przepustowości oraz optymalizacji sieci (ang. *Air Traffic Management* - ATM), to opóźnienie wylotu stanowi miarę pierwotną. Błąd wygenerowany na etapie odlotu determinuje bowiem przebieg operacji w całej przestrzeni powietrznej i obciąża kolejne węzły systemu.

Kluczowym rozróżnieniem w teorii ekonomiki transportu jest podział zakłóceń na opóźnienia pierwotne (*primary delays*) oraz opóźnienia wtórne, nazywane inaczej reakcyjnymi (*reacti-nary delays*). Opóźnienia pierwotne wynikają z bezpośrednich przyczyn przypisanych do danej, konkretnej operacji. Może to być nagłe załamanie pogody nad lotniskiem startowym, niespodziewana awaria techniczna (usterka maszyny), incydent z udziałem pasażera (np. nagłe pogorszenie stanu zdrowia na pokładzie) czy też obostrzenia nałożone w czasie rzeczywistym przez służby kontroli ruchu lotniczego. Z kolei opóźnienia wtórne to zakłócenia „odziedziczone” z poprzednich rotacji maszyny (Jetzki, 2009). Współczesny samolot komercyjny, będący niezwykle kosztownym aktywem trwałym, musi wykazywać wysoki stopień użycia. Aby generować zyski, maszyna przebywa w powietrzu lub w ciągłym ruchu rotacyjnym przez kilkanaście godzin na dobę, wykonując od kilku do kilkunastu rejsów. Z tego względu opóźnienie wygenerowane pierwszym, porannym lotem nie znika. Przeciwnie – potęguje się ono w miarę upływu dnia, tworząc tzw. efekt propagacji (fali), co sprawia, że operacje wieczorne są zazwyczaj obciążone największym błędem harmonogramu.

Z punktu widzenia standardów międzynarodowych organizacji lotniczych (takich jak amerykańska Federalna Administracja Lotnictwa - FAA czy europejska organizacja Eurocontrol), nie każde, nawet kilkuminutowe odchylenie od planu jest traktowane jako usterka operacyjna. Po wszechnie przyjętym, globalnym standardem branżowym jest tolerancja wynosząca 15 minut

(EUROCONTROL, 2024). Przedział ten (od 0 do 15 minut) uznaje się za błąd dopuszczalny, wynikający z natury procesów stochastycznych i nieuniknionych mikrozakłóceń w obsłudze naziemnej. Dopiero przekroczenie tego 15-minutowego progu uruchamia w liniach lotniczych procedury rygorystycznego raportowania przyczyn opóźnienia, co realizowane jest za pomocą ujednoliconego, globalnego systemu kodów IATA (*International Air Transport Association Delay Codes*). System ten pozwala na bezbłędną identyfikację wąskiego gardła – począwszy od kodów serii 10-19 (błędy w obsłudze pasażerskiej i bagażowej), poprzez serię 40-49 (ograniczenia techniczne i awarie), aż po kody serii 80 (restrykcje nałożone przez kontrolę lotów i pogodę).

Należy w tym miejscu zwrócić uwagę na kontrowersyjne, lecz powszechnie stosowane zjawisko sztucznego polepszania statystyk przez przewoźników, znane w literaturze jako *schedule padding* (buforowanie czasu rozkładowego). Ze względu na to, że czas lotu podawany pasażerom to tzw. *block time* (czas od odepchnięcia do dokowania), linie lotnicze celowo wliczają w niego ukryte rezerwy czasowe (Doganis, 2010). Przykładowo, lot trwający fizycznie 60 minut może zostać wpisany w rozkład jako rejs 85-minutowy. Pozwala to linii lotniczej na „zgubienie” niewielkich opóźnień wylotu jeszcze w powietrzu. Pilot, wiedząc o opóźnieniu startu, może poprosić o bezpośrednie wektorowanie (skrót trasy) lub zwiększyć prędkość przelotową (ang. *cost index*), co wiąże się z większym spalaniem paliwa, ale pozwala dotrzeć do portu docelowego zgodnie z rozkładem. Proceder ten sztucznie poprawia statystyki punktualności przylotów w oczach pasażerów oraz urzędów regulacyjnych. Z tego powodu w profesjonalnych badaniach analitycznych to opóźnienie wylotu (*departure delay*) uchodzi za znacznie czystsza, obiektywną miarę efektywności infrastruktury i samych przewoźników.

Opóźnienia wykraczające poza 15-minutową tolerancję charakteryzują się nieliniowym stopniem dotkliwości operacyjnej. Z tego względu w badaniach ilościowych – w szczególności tych wykorzystujących modele uogólnione – zjawisko to dzieli się najczęściej na katégoryczne interwały (Greene, 2003):

- **Opóźnienia małe i akceptowalne (do 15 minut):** Traktowane jako naturalny element środowiska operacyjnego. Nie mają systematycznego, negatywnego wpływu na siatkę połączeń, nie zaburzają pracy załóg i są w większości niwelowane w trakcie trwania rejsu dzięki sprzyjającym prądom strumieniowym lub wspomnianym rezerwom czasowym (*padding*);
- **Opóźnienia średnie (16-45 minut):** Stanowią pierwsze, poważne zagrożenie dla stabilności systemu. Naruszają one zaplanowany czas obsługi naziemnej (*turnaround time*) na kolejnym lotnisku, drastycznie zwiększają ryzyko utraty gwarantowanych przesiadek przez pasażerów w portach węzłowych oraz wymuszają na personelu naziemnym pracę pod presją czasu, co zwiększa ryzyko błędów;
- **Opóźnienia duże i krytyczne (powyżej 45 minut):** Wywołują głębokie perturbacje operacyjne o charakterze systemowym. Zakłócenia tego rzędu nierzadko zmuszają przewoźników do podmiiany załóg ze względu na bezwzględnie rygorystyczne regulacje prawne dotyczące maksymalnego czasu pracy personelu latającego (tzw. normy FTL - *Flight Time Li-*

mitations). Mogą również skutkować koniecznością uruchamiania maszyn rezerwowych, masowym przenoszeniem pasażerów do hoteli lub całkowitym odwoływaniem rotacji (efekt lawinowy).

Zjawisko braku punktualności generuje gigantyczne, wielomiliardowe obciążenia dla światowej gospodarki, które w literaturze rozpatruje się na trzech głównych płaszczyznach kosztowych (Doganis, 2010). Pierwszą z nich stanowią bezpośrednie koszty operacyjne linii lotniczych (tzw. *Direct Operating Costs - DOC*). Obejmują one drastycznie zwiększone zużycie paliwa lotniczego w wyniku dłuższego kołowania (oczekiwania w kolejce do pasa) lub wymuszonego krążenia w strefach holdingowych nad lotniskiem docelowym. W skład DOC wchodzi również wydatki na nadgodziny dla obsługi naziemnej i załóg, a także potężne koszty odszkodowań konsumenckich. W samej tylko Unii Europejskiej restrykcyjne Rozporządzenie WE 261/2004 nakłada na przewoźników obowiązek wypłaty zryczałtowanych odszkodowań (od 250 do 600 EUR na pasażera) za opóźnienia przekraczające 3 godziny, co stanowi istotne zagrożenie dla płynności finansowej linii lotniczych. Do tego dochodzą tzw. koszty miękkie, czyli długoterminowa utrata zaufania i lojalności korporacyjnej (ang. *goodwill*) ze strony najbardziej dochodowego, wysokomarżowego segmentu klientów biznesowych.

Drugą płaszczyzną są koszty ponoszone przez samych pasażerów i gospodarkę makro, definiowane w ekonomii głównie jako koszt utraconych możliwości (*opportunity cost / Value of Time - VoT*). Każda minuta spędzona przez menedżera, inżyniera czy turystę w poczekalni lotniskowej przekłada się na mierzalny spadek produktywności gospodarki. Powoduje to niemożność odbycia kluczowych spotkań handlowych, przerwanie łańcuchów logistycznych, a na poziomie jednostkowym generuje stres i zmęczenie, co pośrednio wpływa na spadek użyteczności całego transportu lotniczego w oczach społeczeństwa.

Trzeci obszar to negatywne efekty zewnętrzne (*externalities*), w tym koszty ekologiczne i systemowe infrastruktury. Wydłużony czas lotów i oczekiwanie z włączonymi silnikami na drogach kołowania generują setki tysięcy ton nadmiarowej emisji dwutlenku węgla (CO<sub>2</sub>) oraz tlenków azotu (NO<sub>x</sub>). Ponadto ciągle zatory powodują przeciążenie kontrolerów ruchu lotniczego, co obniża margines bezpieczeństwa w zarządzaniu przestrzenią powietrzną.

## 2 Uwarunkowania i determinanty punktualności lotów

Identyfikacja i dokładna kwantyfikacja przyczyn opóźnień stanowi najważniejsze wyzwanie zarówno dla zarządców infrastruktury lotniskowej, analityków danych w liniach lotniczych, jak i instytucji państwowych. Prawidłowe modelowanie tego zjawiska wymaga zrozumienia, że punktualność jest wypadkową interakcji dziesiątek zmiennych. W literaturze naukowej oraz w oficjalnych raportach agencji lotniczych uwarunkowania te dzieli się tradycyjnie na dwie nadrzędne kategorie: czynniki egzogeniczne (zewnętrzne, w dużej mierze niezależne od decydentów biznesowych) oraz endogeniczne (wewnętrzne, wynikające wprost z przyjętych procesów

operacyjnych i modeli biznesowych) (International Air Transport Association, 2023).

W powszechnej świadomości pasażerów oraz w relacjach medialnych, absolutnie głównym winowajcą opóźnień są niekorzystne warunki atmosferyczne. Rzeczywiście, parametry meteorologiczne mają bezpośredni, twardy wpływ na bezpieczeństwo operacji oraz przepustowość krzyżową lotnisk (tzw. *runway throughput*). Ekstremalne zjawiska, takie jak silne wiatry boczne (*crosswinds*) czy gwałtowne zmiany kierunku i siły wiatru przy samej ziemi (*wind shear*), wymuszają zmianę kierunków operacji na pasach startowych, co często wymaga wstrzymania ruchu na czas rekonfiguracji podejść. Gwałtowne burze konwekcyjne w miesiącach letnich generują z kolei problemy na etapie przelotu (*en-route*), zmuszając samoloty do omijania stref niebezpiecznych w promieniu kilkudziesięciu mil, co wydłuża trasę i czas lotu. W miesiącach zimowych intensywne opady śniegu lub marznący deszcz uruchamiają konieczność przeprowadzenia niezwykle czasochłonnnych procedur odladzania maszyn (*de-icing*) na specjalnych stanowiskach przed startem, a także wymuszają ciągłe odśnieżanie dróg kołowania. Podobnie skrajnie niska widoczność (mgła) zmusza porty lotnicze do aktywacji rygorystycznych procedur LVP (*Low Visibility Procedures*), które ze względów bezpieczeństwa drastycznie zwiększają wymagane separacje czasowe i odległościowe między lądującymi samolotami. Należy jednak stanowczo zaznaczyć, że postęp technologiczny – w tym zaawansowane systemy lądowania według przyrządów (ILS Kategorii III), pozwalające na lądowania bez widoczności ziemi – potrafią w znacznym stopniu mitygować te zagrożenia (Doganis, 2010). Współcześni analitycy zwracają uwagę, że to, co oficjalnie raportowane jest często jako "opóźnienie pogodowe", w rzeczywistości maskuje niewydolność operacyjną przewoźnika lub brak elastyczności systemu w warunkach zwiększonego stresu operacyjnego.

Z tego powodu najnowsza literatura transportowa coraz silniej akcentuje czynniki endogeniczne, w szczególności organizacyjne, jako prawdziwie kluczowe determinanty powstawania nieodwracalnych zatorów. Najważniejszym aspektem analitycznym jest w tym kontekście model biznesowy i specyfika polityki konkretnej linii lotniczej. To właśnie decyzje podejmowane w zarządach linii determinują elastyczność i odporność siatki połączeń na ewentualne błędy (Doganis, 2010).

W ujęciu strukturalnym wyraźnie zarysowuje się konflikt między dwoma dominującymi modelami: tradycyjnymi przewoźnikami sieciowymi (*Legacy Carriers*, np. Lufthansa, Delta Airlines, LOT) a tanimi liniami lotniczymi (*Low-Cost Carriers - LCC*, np. Ryanair, Wizz Air, Spirit). Przewoźnicy niskokosztowi budują swoją agresywną rentowność rynkową na maksymalizacji stopnia wykorzystania floty (*aircraft utilization rate*). Aby samolot przynosił zyski przy bardzo niskich cenach biletów, musi latać nieprzerwanie, nawet do 14-15 godzin na dobę. Wymusza to na liniach LCC planowanie ekstremalnie krótkich czasów obsługi maszyny na ziemi, czyli tzw. *turnaround time*. Pomiędzy dojazdem samolotu na stanowisko a jego ponownym wypchnięciem mija często zaledwie od 25 do 35 minut (Allain i Ben Omrane, 2004). Taka mordercza optymalizacja sprawia, że system zostaje całkowicie pozbawiony jakichkolwiek rezerw i buforów. Nawet najmniejsze, kilkuminutowe potknięcie – spóźniony pasażer, zacięty rękaw lotniskowy, problem

z tankowaniem czy wolniejsze sprzątanie kabiny – staje się matematycznie niemożliwe do nadrobienia. W rezultacie opóźnienie zyskuje charakter chroniczny i przenosi się na każdy kolejny lot danej maszyny aż do późnej nocy.

Z kolei potężni tradycyjni przewoźnicy sieciowi zmagają się z zupełnie innym wyzwaniem strukturalnym – koniecznością synchronizacji wielkich fal przesiadkowych. Ich model operacyjny oparty jest na scentralizowanej architekturze piasty i szprych (*hub-and-spoke*). Duże lotnisko węzłowe (np. Frankfurt, Atlanta) gromadzi ruch z mniejszych lotnisk regionalnych (*feeder flights*), aby połączyć pasażerów na zyskowe, międzykontynentalne trasy długodystansowe. Model ten wymusza na dyspozytorach linii lotniczych podejmowanie skrajnie trudnych decyzji. W sytuacji, gdy jeden mały samolot dowożący kilkunastu kluczowych pasażerów transferowych ulega opóźnieniu, przewoźnik celowo wstrzymuje wylot wielkiego samolotu transoceanicznego (Jetzki, 2009). Taka polityka oczekiwania ratuje wizerunek firmy u klienta i pozwala uniknąć wypłaty gigantycznych odszkodowań czy rezerwacji hoteli, ale bezlitośnie i świadomie pogarsza ogólne statystyki punktualności wyjściowej hubu, opóźniając start o kilkadziesiąt minut. Mechanizm ten generuje najgroźniejszy w lotnictwie efekt domina (*delay propagation*), w którym jedno zakłócenie na skraju sieci, wskutek zależności kapitałowych i ludzkich, w ułamku doby paraliżuje operacje na zupełnie innym kontynencie.

Nie bez znaczenia dla holistycznego modelowania punktualności pozostają również uwarunkowania infrastrukturalne oraz zmienne czasowe. System lotniczy wykazuje nieprawdopodobnie silną sezonowość. Miesiące letnie generują zakłócenia wynikające z ekstremalnego nasycenia europejskiej i amerykańskiej przestrzeni powietrznej wakacyjnymi lotami czarterowymi oraz zwiększoną aktywnością burzową. Z kolei miesiące zimowe obciążają przepustowość procedurami utrzymania nawierzchni pasów startowych. Co więcej, fizyczna przepustowość lotnisk, dróg kołowania i terminali jest wielkością stałą, podczas gdy popyt wykazuje ostre wahania w cyklu dobowym. Pasażerowie preferują wyloty w określonych porach dnia, co sprawia, że harmonogramy lotów grupują się w potężne fale wylotowe i przylotowe (*waves / banks / peak hours*). Poranne operacje zazwyczaj startują z "czystą kartą", a system posiada jeszcze wolne zasoby, co skutkuje najwyższą punktualnością. Jednakże w miarę upływu dnia i nawarstwiania się opisanych wyżej problemów linii LCC oraz ograniczeń sieciowych hubów, systematycznej degradacji ulega płynność całego ruchu. Pora dnia staje się zatem kluczową zmienną kontrolną, determinującą prawdopodobieństwo natrafienia na załamanie przepustowości.

### 3 Metody ilościowe w badaniach transportu lotniczego

Współczesny globalny transport lotniczy to system generujący każdego dnia dziesiątki petabajtów danych. Powszechna cyfryzacja zarządzania ruchem lotniczym, obligatoryjna implementacja systemów ciągłego śledzenia statków powietrznych opartych na satelitarnej technologii ADS-B (*Automatic Dependent Surveillance–Broadcast*) oraz funkcjonowanie otwartych, rządowych repozytoriów danych (takich jak gigantyczne bazy amerykańskiego *Bureau of Transporta-*

tion Statistics - BTS) sprawiły, że branża lotnicza stała się jednym z najbardziej rozbudowanych i wymagających środowisk analitycznych typu Big Data. Ze względu na ten hipermasowy i wielowymiarowy charakter zbiorów danych, rzetelne badanie zjawiska opóźnień wykracza daleko poza proste narzędzia statystyki opisowej. Identyfikacja rzeczywistych zależności i predykcja zdarzeń wymusza na badaczach zjawisk transportowych stosowanie coraz bardziej zaawansowanego, nieliniowego aparatu matematycznego.

Historycznie w badaniach nad rynkiem transportowym absolutnie dominowała klasyczna, strukturalna ekonometria. Pierwotne próby modelowania punktualności traktowały opóźnienie wprost jako zmienną ciągłą (wyrażoną w dokładnych minutach). Do szacowania wpływu czynników (takich jak odległość trasy czy temperatura) wykorzystywano najczęściej Klasyczną Metodę Najmniejszych Kwadratów (regresja wieloraka KMNK / OLS). Narzędzie to, choć stanowi kamień węgielny klasycznej ekonomii i ekonometrii, bardzo szybko ujawniło swoje fundamentalne bariery w starciu ze specyfiką danych lotniczych (Greene, 2003). Empiryczny rozkład opóźnień charakteryzuje się bowiem skrajną asymetrią i silną prawostronną skośnością. Dominująca większość rejsów wykonywana jest punktualnie lub z odchyleniem rzędu kilku minut (co w statystyce określa się mianem problemu nadmiaru zer – ang. *zero-inflated data distribution*). Z drugiej jednak strony, rozkład ten posiada charakterystyczny „gruby ogon” (*fat tail*), w którym kryją się stosunkowo rzadkie, ale ekstremalne i kluczowe poznawczo zatory rzędu kilkuset minut. Próba sztucznego dopasowania sztywnej, liniowej funkcji regresji do tak rozproszonych danych skutkuje kategorię łamaniem fundamentalnych założeń metody Gaussa-Markowa. Analitycy zmagają się wówczas z problemem braku normalności rozkładu reszt oraz drastyczną heteroskedastycznością wariancji składnika losowego. W efekcie estymatory OLS tracą cechę efektywności, a wnioskowanie statystyczne oparte na tradycyjnych testach (np. teście t-Studenta) staje się niewiarygodne i potencjalnie obciążone.

Świadomość tych ograniczeń doprowadziła do rewolucji metodycznej. Na przełomie wieków badacze zjawisk transportowych zaczęli masowo odchodzić od prób predykcji dokładnej, pojedynczej minuty spóźnienia samolotu. Zamiast tego zwrócili się ku klasie modeli zmiennych jakościowych (dyskretnych), znacznie lepiej odpowiadających biznesowym potrzebom linii lotniczych. Podejście to opiera się na transformacji ciągłego czasu trwania zdarzenia w logicznie uporządkowane szufladki kategoryjne (np. opóźnienie małe, średnie, duże) i wyliczaniu prawdopodobieństwa trafienia konkretnego lotu do jednej z nich. Największą popularność na tym polu zyskały probabilistyczne modele logitowe i probitowe.

Szczególnym i niezwykle potężnym w zastosowaniach lotniczych wariantem tego podejścia stał się Uporządkowany Model Logitowy (*Ordered Logit* lub model proporcjonalnych szans - *Proportional Odds Model*) (Greene, 2003). Jego genialność polega na zdolności do matematycznego odzwierciedlenia naturalnej, rosnącej hierarchii zjawiska. Mechanika modelu uwzględnia fakt, że przejście z kategorii opóźnienia małego do średniego to postępujący ciąg tego samego zjawiska. Największą, pragmatyczną zaletą modeli z rodziny logitowej jest jednak ich transparentność i interpretowalność wyników. Wynikiem estymacji parametrów są łatwo mierzalne

Ilorazy Szans (*Odds Ratios* - OR). Pozwalają one badaczom i menedżerom wprost sformułować wnioski biznesowe w rodzaju: „wykonanie rejsu późnym wieczorem zwiększa szansę na wpadnięcie do gorszej kategorii opóźnienia o 45% w stosunku do lotu porannego”.

Ostatnia dekada przyniosła jednak w naukach o danych kolejny potężny paradygmat, który coraz silniej przenika do ekonomiki transportu – zastosowanie algorytmów uczenia maszynowego (*Machine Learning* - ML). Metody bazujące na sztucznej inteligencji, takie jak Lasy Losowe (*Random Forest* - RF), Maszyny Wektorów Nośnych (*Support Vector Machines* - SVM), zaawansowany Gradient Boosting (np. algorytmy XGBoost) czy też Głębokich Sieciach Neuro-nowych (*Deep Learning* / ANN), stanowią całkowicie odmienną, inżynierską filozofię badawczą (AlBassam i AlShahrani, 2025). W przeciwieństwie do klasycznej ekonometrii, nowoczesne algorytmy ML wywodzą się z rodziny metod nieparametrycznych. Oznacza to, że nie wymuszają na analityku wcześniejszego określenia kształtu funkcji, nie boją się kolinearności zmiennych i nie narzucają na zbiór uczący żadnych rygorystycznych założeń dotyczących jego rozkładu czy homoskedastyczności.

Zastosowanie algorytmów opartych na agregacji drzew decyzyjnych (*ensemble learning*), takich jak Lasy Losowe, okazało się ogromnym przełomem w badaniu systemów nieliniowych. Lasy Losowe budują setki niezależnych ścieżek decyzyjnych dla różnych podzbiorów danych, a ostateczny wynik ustalają na drodze tzw. głosowania większościowego. Wykazują one wybitną, niedoścignioną dla klasycznej ekonometrii zdolność do samoczynnego wyłapywania wielowymiarowych interakcji (np. faktu, że konkretna, lokalna linia lotnicza radzi sobie świetnie w słoneczny poranek, ale całkowicie paraliżuje lotnisko podczas deszczowego popołudnia na określonym kierunku operacyjnym). Ich główną przewagą analityczną jest drastyczna poprawa zdolności klasyfikacji rzadkich anomalii systemowych (krytycznych zakłóceń >45 minut), z którymi klasyczne logity często mają problem z powodu matematycznej tendencji do uśredniania prawdopodobieństw dla klas dominujących (lotów punktualnych). Rozwój metod ML wymusił również zmianę w sposobie ewaluacji jakości modeli. Podczas gdy w regresji liniowej złotym standardem był wskaźnik R-kwadrat, w lotniczej analizie klasyfikacyjnej nadrzędną rolę zaczęły pełnić wskaźniki odporne na asymetrię danych (tzw. zbiory niezbalansowane), takie jak Precyzja, Czułość (*Recall*) czy wreszcie zintegrowany wskaźnik *F1-Score*.

Wybór ostatecznego narzędzia matematycznego dla celów pracy dyplomowej czy też wdrożenia rynkowego stawia analityka przed jednym z najsłynniejszych dylematów we współczesnej analityce danych: *Inference vs. Prediction* (Wnioskowanie czy Prognozowanie). Badacz musi określić priorytet. Jeśli celem jest stworzenie doskonałego operacyjnie oprogramowania dla linii lotniczej, potrafiącego z najwyższą trafnością (Accuracy/F1-Score) odseparować i przewidzieć najcięższe zakłócenia, naturalnym wyborem będą czarne skrzynki uczenia maszynowego (Random Forest). Jeśli jednak nadrzędnym celem instytucji regulacyjnej (bądź autora pracy akademickiej) jest głębokie zrozumienie samej mechaniki rynkowej i ocena istotności statystycznej danego zjawiska, wybór powinien paść na rygorystyczny model ekonometryczny (Ordered Logit) (AlBassam i AlShahrani, 2025). Modele parametryczne pozwalają otworzyć system i zajrzeć

w strukturę kosztów oraz szans, podczas gdy AI dostarcza jedynie końcowy wynik. Z tego właśnie powodu w najbardziej zaawansowanych, współczesnych pracach badawczych dotyczących inżynierii transportowej kategorycznie zaleca się jednoczesne stosowanie i zderzanie ze sobą obu tych skrajnych podejść metodologicznych, co gwarantuje pełną i rzetelną triangulację wyników naukowych.

# Rozdział 2

## Metodologia badań

Niniejszy rozdział poświęcony jest szczegółowemu opisowi aparatu matematycznego oraz metod statystycznych wykorzystanych w procesie analizy empirycznej. Zrozumienie mechanizmów rządzących punktualnością w transporcie lotniczym wymaga wyjścia poza ramy klasycznej ekonometrii liniowej, dlatego fundamentem prowadzonych badań uczyniono modele nieliniowe, które pozwalają na precyzyjne kwantyfikowanie zjawisk o charakterze jakościowym.

### 1 Uogólnione Modele Liniowe (GLM) i fundamenty regresji logistycznej

W modelowaniu zjawisk ekonomicznych, w których zmienna objaśniana przyjmuje wartości dyskretne, standardowe podejście oparte na Klasycznej Metodzie Najmniejszych Kwadratów (KMNK) okazuje się niewystarczające. Modele regresji logistycznej wykorzystywane są powszechnie do objaśniania takich zmiennych jakościowych w zależności od poziomu rozpatrywanych zmiennych egzogenicznych (Jackowska, 2011). W tym punkcie przedstawione zostaną teoretyczne podstawy przejścia od modeli liniowych do klasy Uogólnionych Modeli Liniowych (GLM), ze szczególnym uwzględnieniem regresji logistycznej.

#### 1.1 Ograniczenia modelu liniowego (LPM)

Zastosowanie regresji liniowej do analizy zmiennej jakościowej (np. wystąpienie opóźnienia lub jego brak) prowadzi do powstania Modelu Liniowego Prawdopodobieństwa (ang. *Linear Probability Model* – LPM). Model ten można zapisać jako:

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (2.1)$$

gdzie  $E(y_i | \mathbf{x}_i) = P(y_i = 1 | \mathbf{x}_i) = \mathbf{x}_i' \boldsymbol{\beta}$ . Jak wskazuje W. Greene (Greene, 2003), takie podejście obarczone jest szeregiem wad, które dyskwalifikują je w profesjonalnych analizach mikroeko-

nometrycznych:

1. *Nielogiczne wartości prawdopodobieństwa*: Funkcja liniowa  $\mathbf{x}_i'\beta$  nie jest ograniczona w przedziale  $[0, 1]$ . W praktyce oznacza to, że dla niektórych zestawów zmiennych objaśniających (np. ekstremalne warunki pogodowe), model może oszacować prawdopodobieństwo ujemne lub przekraczające jedność, co jest sprzeczne z aksjomatami Kołmogorowa.
2. *Heteroskedastyczność*: W modelu LPM wariancja składnika losowego nie jest stała i zależy od wartości zmiennych objaśniających:  $Var(\varepsilon_i) = \mathbf{x}_i'\beta(1 - \mathbf{x}_i'\beta)$ . Powoduje to, że estymatory KMNK tracą cechę efektywności, a standardowe błędy oszacowań stają się niewiarygodne (Maddala, 1983).
3. *Nienormalność rozkładu składnika losowego*: Ponieważ zmienna  $y_i$  przyjmuje tylko dwie wartości, składnik losowy  $\varepsilon_i$  również musi być dwupunktowy, co uniemożliwia przyjęcie założenia o normalności rozkładu niezbędnego do weryfikacji hipotez statystycznych w małych próbach.

## 1.2 Koncepcja Uogólnionych Modeli Liniowych (GLM)

Problemy modelu LPM rozwiązuje koncepcja GLM, która pozwala na modelowanie wartości oczekiwanej zmiennej zależnej poprzez nieliniową funkcję łączącą. Model logitowy jest w istocie szczególnym przypadkiem uogólnionego modelu liniowego (Jackowska, 2011). Zgodnie z definicją T. Hastie i in. (Hastie i in., 2009), model ten definiują trzy elementy:

- *Składnik losowy*: Rozkład zmiennej  $y$  należący do rodziny wykładniczej.
- *Predyktor liniowy*:  $\eta = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$ .
- *Funkcja łącząca (link function)*: Funkcja  $g(\cdot)$ , która wiąże wartość oczekiwaną zmiennej  $\mu = E(y)$  z liniową kombinacją predyktorów, zadaną równaniem  $g(\mu) = \mathbf{x}'\beta$  (Jackowska, 2011).

## 1.3 Regresja logistyczna i pojęcie logitu

Jeżeli w badaniu zmienna objaśniana przyjmuje dokładnie dwa stany (tzn. informuje nas jednoznacznie, czy badane zjawisko opóźnienia wystąpiło, czy też nie), to mamy do czynienia z modelem dwumianowym (Jackowska, 2011). W takiej regresji logistycznej funkcją łączącą jest funkcja logitowa. Zakładamy, że prawdopodobieństwo wystąpienia zdarzenia  $p$  jest opisane dystrybuantą rozkładu logistycznego:

$$p_i = \frac{1}{1 + e^{-\mathbf{x}_i'\beta}} \quad (2.2)$$

Kluczowym pojęciem jest tu **szansa** (ang. *odds*), definiowana jako iloraz prawdopodobieństwa wystąpienia zdarzenia oraz prawdopodobieństwa niewystąpienia tego zdarzenia (Jackowska, 2011):

$$\frac{p_i}{1 - p_i} = e^{\mathbf{x}_i' \boldsymbol{\beta}} \quad (2.3)$$

Logarytmując powyższe wyrażenie, otrzymujemy liniową postać modelu, w której wspomniana wcześniej funkcja wiążąca nazywana jest **logitem** (Jackowska, 2011):

$$L_i = \ln \left( \frac{p_i}{1 - p_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} \quad (2.4)$$

Transformacja ta pozwala na estymację parametrów modelu za pomocą metody Największej Wiarygodności (MLE), co w praktyce oznacza maksymalizację logarytmu funkcji wiarygodności przy użyciu numerycznych procedur iteracyjnych (Jackowska, 2011).

## 1.4 Interpretacja parametrów i ilorazy Szans (Odds Ratios)

Jedną z największych zalet modelu logitowego jest możliwość stosunkowo prostej interpretacji parametrów  $e^{\beta_i}$  (Jackowska, 2011). Ze względu na logarytmiczną transformację, bezpośrednio współczynniki  $\beta$  informują o zmianie logarytmu szansy, a nie samego prawdopodobieństwa. W celu nadania wynikom interpretacji ekonomicznej stosuje się transformację wykładniczą parametrów, wyznaczając tzw. **ilorazy Szans** (ang. *Odds Ratios* – OR):

$$OR = \exp(\beta_j) \quad (2.5)$$

Interpretacja wyników zależy od charakteru zmiennych oraz przypisanych wartości bazowych:

- **Wyraz wolny:** wartość  $e^{\beta_0}$  interpretowana jest jako szansa wystąpienia zjawiska w grupie referencyjnej, dla której wszystkie pozostałe zmienne objaśniające wynoszą zero (Jackowska, 2011).
- **Zmienna dychotomiczna:** jeżeli badana zmienna  $x_j$  jest zmienną zero-jedynkową, to używany współczynnik  $e^{\beta_j}$  jest równy ilorazowi szans dla grupy, w której zmienna przyjmuje wartość 1, w stosunku do grupy, gdzie zmienna równa jest 0, przy zachowaniu stałości pozostałych parametrów (Jackowska, 2011).
- **Zmienna ilościowa:** w przypadku zmiennych ciągłych iloraz szans  $e^{\beta_j}$  informuje, jak zmieni się szansa wystąpienia opóźnienia, jeżeli zmienna ta wzrośnie o dokładnie jedną jednostkę (Jackowska, 2011).

Ogólnie wskaźnik  $OR$  pozwala na szybką identyfikację kierunku wpływu:  $OR > 1$  oznacza, że wzrost zmiennej objaśniającej zwiększa szansę wystąpienia zdarzenia, natomiast  $OR < 1$

wskazuje na relację odwrotną. Wartość  $OR = 1$  oznacza brak istotnego wpływu zmiennej na szansę wystąpienia badanego zjawiska.

## 2 Uporządkowany model wielomianowy (Ordered Logit Model)

W praktyce analitycznej zjawisk społeczno-gospodarczych często spotyka się sytuacje, w których zmienna objaśniana ma charakter jakościowy, a jej warianty (kategorie) pozostają w ściśle określonej, naturalnej hierarchii. Przykładem takiej struktury są stopnie oceny ryzyka kredytowego, poziomy wykształcenia, czy – jak w przypadku niniejszej pracy – rosnące kategorie wielkości opóźnień w transporcie lotniczym. W takich przypadkach aparat analityczny musi zostać odpowiednio rozszerzony, a właściwym narzędziem statystycznym staje się uporządkowany model wielomianowy (ang. *Ordered Logit Model* lub *Proportional Odds Model*).

### 2.1 Rozszerzenie modelu binarnego na dane porządkowe

Klasyczna regresja logistyczna, ze względu na swoją architekturę, ogranicza się do modelowania zjawisk dychotomicznych (dwustanowych). Próba analizy zjawisk wieloklasowych za pomocą prostych modeli napotyka na fundamentalne przeszkody. Jak zauważa G.S. Maddala (Maddala, 1983), zastosowanie zwykłej Klasycznej Metody Najmniejszych Kwadratów (KMNK) do danych porządkowych poprzez przypisanie im arbitralnych wartości liczbowych (np. 1 dla małego opóźnienia, 2 dla średniego, 3 dla dużego) jest błędem metodologicznym. Regresja liniowa zakłada bowiem, że dystans (różnica natężenia cechy) między kategorią 1 a 2 jest dokładnie taki sam, jak między kategorią 2 a 3. W rzeczywistości rynkowej odstępstwa te są nieznane i z reguły asymetryczne.

Alternatywą mogłoby być zastosowanie nieuporządkowanego modelu wielomianowego (ang. *Multinomial Logit Model*), który rozszerza analizę na wiele klas. Jednakże model ten traktuje kategorie jako całkowicie niezależne i nominalne (jak np. wybór środka transportu: pociąg, autobus, samolot). Zastosowanie go do danych o opóźnieniach prowadziłoby do bezpowrotnej utraty cennej informacji o tym, że opóźnienie średnie jest w naturalny sposób "gorsze" od małego, a mniejsze od krytycznego. Uporządkowany model logitowy rozwiązuje ten problem, stanowiąc ewolucyjne rozwinięcie modelu binarnego, w którym mechanizm szacowania prawdopodobieństw uwzględnia i chroni porządkowy charakter (ranking) analizowanych klas (Greene, 2003).

### 2.2 Koncepcja zmiennej ukrytej (Latent Variable)

Fundamentem teoretycznym uporządkowanego modelu wielomianowego jest założenie o istnieniu w systemie nieobserwowalnej, ciągłej zmiennej ukrytej, oznaczanej w literaturze ekonometrycznej jako  $y^*$ . Zmienną tę należy interpretować jako niemierzalną bezpośrednio "skłon-

ność” (ang. *propensity*) badanego systemu do wygenerowania określonego zdarzenia – w tym wypadku: skłonność systemu operacyjnego linii lotniczej do generowania zakłóceń czasowych (Greene, 2003).

Zmienna ukryta opisana jest ciągłym równaniem strukturalnym, które w zapisie macierzowym przyjmuje postać:

$$y_i^* = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad \text{dla } i = 1, \dots, n \quad (2.6)$$

gdzie:

- $y_i^*$  oznacza wartość ciągłej, nieobserwowalnej zmiennej ukrytej dla  $i$ -tej obserwacji;
- $\mathbf{x}_i$  jest wektorem wartości zmiennych objaśniających (predyktorów), takich jak warunki meteorologiczne, infrastrukturalne czy organizacyjne;
- $\boldsymbol{\beta}$  to wektor nieznanych parametrów strukturalnych (współczynników modelu), które odzwierciedlają kierunek i siłę wpływu poszczególnych zmiennych na skłonność do opóźnień;
- $\varepsilon_i$  reprezentuje losowy składnik błędu (składnik resztowy).

Kluczowym założeniem modelu logitowego jest przyjęcie specyficznego rozkładu dla składnika losowego  $\varepsilon_i$ . Zakłada się, że posiada on standardowy rozkład logistyczny o wartości oczekiwanej równej zero ( $E(\varepsilon) = 0$ ) oraz wariancji równej  $\pi^2/3$ . Dystrybuenta tego rozkładu, oznaczana najczęściej jako  $\Lambda(\cdot)$  lub  $F(\cdot)$ , wyraża się zwartym wzorem analitycznym:

$$F(\varepsilon) = \frac{\exp(\varepsilon)}{1 + \exp(\varepsilon)} \quad (2.7)$$

To właśnie właściwości tego rozkładu – w szczególności nieznaczenie ”grubsze ogony” w porównaniu z rozkładem normalnym – sprawiają, że modele logitowe charakteryzują się wysoką odpornością (ang. *robustness*) na występowanie w próbie badawczej wartości odstających, co jest zjawiskiem niezwykle powszechnym w masowych danych transportowych (Hastie i in., 2009).

## 2.3 Mechanika progów (Cut-points) i prawdopodobieństwa warunkowe

Chociaż zmienna ukryta  $y^*$  ma charakter ciągły i rozciąga się od minus do plus nieskończoności, w rzeczywistości badacz obserwuje jedynie dyskretne, kategoriowe realizacje tej zmiennej, oznaczane jako  $y$ . Związek pomiędzy nieobserwowalną skłonnością  $y_i^*$  a empirycznie obserwowalną kategorią  $y_i$  definiuje mechanizm progów odcięcia (ang. *cut-points* lub *thresholds*), oznaczanych grecką literą  $\mu$ .

W modelu uwzględniającym  $J$  uporządkowanych kategorii istnieje dokładnie  $J - 1$  nieznanych progów odcięcia. Proces dyskretyzacji zmiennej ukrytej przebiega według następującego

schematu (Greene, 2003):

$$y_i = \begin{cases} 1 & \text{jeżeli } y_i^* \leq \mu_1 \\ 2 & \text{jeżeli } \mu_1 < y_i^* \leq \mu_2 \\ 3 & \text{jeżeli } \mu_2 < y_i^* \leq \mu_3 \\ \vdots & \vdots \\ J & \text{jeżeli } y_i^* > \mu_{J-1} \end{cases} \quad (2.8)$$

Aby model był możliwy do oszacowania (identyfikowalny matematycznie), musi zostać spełniony warunek ścisłej monotoniczności progów:  $\mu_1 < \mu_2 < \dots < \mu_{J-1}$ . Progi te pełnią funkcję "barier przejścia". W kontekście lotniczym, wraz z pogarszaniem się warunków (np. wzrostem siły wiatru), rośnie wartość zmiennej ukrytej  $y^*$ . Kiedy  $y^*$  przekracza pierwszy próg  $\mu_1$ , opóźnienie lotu przeskakuje z kategorii małej do średniej. Przekroczenie kolejnego progu  $\mu_2$  oznacza już kategoryzację zdarzenia jako opóźnienia wielkiego (krytycznego).

Ponieważ równanie strukturalne zawiera składnik losowy  $\varepsilon_i$ , nie można ze stuprocentową pewnością określić, do której kategorii trafi dana obserwacja. Zamiast tego, ekonometria pozwala na wyliczenie prawdopodobieństwa warunkowego, z jakim obserwacja znajdzie się w określonej klasie, pod warunkiem zaobserwowania danego wektora  $\mathbf{x}_i$ .

Prawdopodobieństwo, że zmienna obserwowana  $y$  przyjmie wartość równą lub mniejszą od  $j$ , jest równoznaczne z prawdopodobieństwem, że zmienna ukryta  $y^*$  nie przekroczy progu  $\mu_j$ . Wykorzystując dystrybuentę rozkładu logistycznego  $F(\cdot)$ , można zapisać to prawdopodobieństwo skumulowane następująco (Maddala, 1983):

$$P(y_i \leq j | \mathbf{x}_i) = P(y_i^* \leq \mu_j) = P(\mathbf{x}_i' \beta + \varepsilon_i \leq \mu_j) = P(\varepsilon_i \leq \mu_j - \mathbf{x}_i' \beta) \quad (2.9)$$


Co po podstawieniu do wzoru na dystrybuentę daje ostateczną postać modelu prawdopodobieństwa skumulowanego:

$$P(y_i \leq j | \mathbf{x}_i) = \frac{1}{1 + \exp(-(\mu_j - \mathbf{x}_i' \beta))} \quad (2.10)$$

Ostatecznie, aby obliczyć prawdopodobieństwo przynależności badanej jednostki do jednej, konkretnej kategorii  $j$ , należy wyznaczyć różnicę odpowiednich wartości dystrybuanty. Geometria tego zagadnienia sprowadza się do obliczenia pola pod krzywą rozkładu logistycznego, znajdującego się pomiędzy dwoma sąsiadującymi progami odcięcia:

$$P(y_i = j | \mathbf{x}_i) = F(\mu_j - \mathbf{x}_i' \beta) - F(\mu_{j-1} - \mathbf{x}_i' \beta) \quad (2.11)$$

Dla skrajnych przedziałów przyjmuje się, że  $\mu_0 = -\infty$  oraz  $\mu_J = +\infty$ , co sprawia, że dystrybuenta  $F(-\infty) = 0$ , a  $F(+\infty) = 1$ . Zatem dla pierwszej kategorii ( $j = 1$ ) wzór upraszcza się do  $F(\mu_1 - \mathbf{x}_i' \beta)$ , a dla kategorii ostatniej ( $j = J$ ) do  $1 - F(\mu_{J-1} - \mathbf{x}_i' \beta)$ .



**Rysunek 2.1:** Mechanika progów odcięcia i kategoryzacja zmiennej ukrytej w modelu Ordered Logit.

## 2.4 Założenie o proporcjonalności szans (Parallel Regression Assumption)

Należy podkreślić, że klasyczny Uporządkowany Model Logitowy opiera się na bardzo restrykcyjnym założeniu, znanym jako założenie o proporcjonalności szans (ang. *Proportional Odds Assumption* lub *Parallel Regression Assumption*). Oznacza to, że wektor parametrów strukturalnych  $\beta$  jest identyczny i stały (niezmienniczy) dla wszystkich punktów podziału  $j$  (Greene, 2003).

W ujęciu algebraicznym, model zakłada, że krzywe prawdopodobieństwa opisujące poszczególne kategorie są względem siebie idealnie równoległe, a to, co ulega zmianie przy przejściu między kategoriami, to wyłącznie współczynniki wyrazu wolnego, reprezentowane przez wartości progów odcięcia  $\mu_j$  (Jackowska, 2011). Oznacza to, że wpływ danej zmiennej objaśniającej (np. spadku temperatury) na szansę przesunięcia się lotu z kategorii punktualnej do opóźnionej jest strukturalnie dokładnie taki sam, jak wpływ tej samej zmiennej na przesunięcie się lotu z opóźnienia małego do kategorii ekstremalnego, wielogodzinnego zatoru. Właściwość ta nadaje modelowi ogromną elegancję matematyczną i stabilność estymatorów, a oszacowane parametry zachowują globalny, uniwersalny charakter w odniesieniu do całego spektrum analizowanego zjawiska.

## 3 Estymacja parametrów modelu metodą Największej Wiarygodności

Wybór odpowiedniej metody szacowania parametrów strukturalnych jest determinowany przez nieliniowy charakter funkcji prawdopodobieństwa w modelu *Ordered Logit*. W przeciwieństwie do modeli liniowych, gdzie dominującym narzędziem jest Klasyczna Metoda Najmniejszych Kwadratów, w modelach zmiennych jakościowych standardem jest metoda Największej Wiarygodności (ang. *Maximum Likelihood Estimation* – MLE).

### 3.1 Zasada działania i fundamenty koncepcyjne MLE

Istota metody Największej Wiarygodności opiera się na odwróceniu perspektywy klasycznego wnioskowania probabilistycznego. O ile rachunek prawdopodobieństwa pozwala określić szansę wystąpienia danych przy znanych parametrach populacji, o tyle MLE służy do znalezienia takich wartości parametrów  $\beta$  oraz  $\mu$ , dla których zaobserwowana w próbie badawczej kombinacja zdarzeń jest najbardziej prawdopodobna (Greene, 2003).

Koncepcyjnie metoda ta zakłada, że posiadana próba danych jest reprezentatywnym odzwierciedleniem procesu generującego dane. Szukamy zatem wektora parametrów, który maksymalizuje funkcję wiarygodności, co w ujęciu statystycznym zapewnia uzyskanie estymatorów o pożądanych właściwościach asymptotycznych: zgodności, asymptycznej efektywności oraz asymptycznej normalności (Diebold i Schuermann, 1996). Jak wskazują Diebold i Schuermann (Diebold i Schuermann, 1996), precyzyjne (dokładne) podejście do konstrukcji funkcji wiarygodności jest kluczowe dla zachowania jakości predykcji w modelach ekonometrycznych operujących na dużych zbiorach danych.

### 3.2 Konstrukcja funkcji wiarygodności i log-wiarygodności

Punktem wyjścia do estymacji jest zdefiniowanie funkcji wiarygodności  $L(\beta, \mu)$ , która dla niezależnych obserwacji jest iloczynem prawdopodobieństw wystąpienia konkretnych kategorii  $j$ , zaobserwowanych dla każdej  $i$ -tej jednostki w próbie. Można ją zapisać jako:

$$L(\beta, \mu) = \prod_{i=1}^n \prod_{j=1}^J [P(y_i = j | \mathbf{x}_i)]^{d_{ij}} \quad (2.12)$$

gdzie  $d_{ij}$  jest zmienną indykatorową przyjmującą wartość 1, jeżeli dla  $i$ -tej obserwacji wystąpiła kategoria  $j$ , oraz 0 w przeciwnym razie. Podstawiając wyprowadzone wcześniej wzory na prawdopodobieństwa w modelu *Ordered Logit*, otrzymujemy:

$$L(\beta, \mu) = \prod_{i=1}^n \prod_{j=1}^J [F(\mu_j - \mathbf{x}_i' \beta) - F(\mu_{j-1} - \mathbf{x}_i' \beta)]^{d_{ij}} \quad (2.13)$$

Z operacyjnego punktu widzenia, maksymalizacja iloczynu wielu prawdopodobieństw jest zadaniem trudnym numerycznie. Dlatego w praktyce ekonometrycznej dokonuje się transformacji logarytmicznej, przechodząc do logarytmicznej funkcji wiarygodności (ang. *Log-Likelihood*):

$$\ln L(\beta, \mu) = \sum_{i=1}^n \sum_{j=1}^J d_{ij} \ln [F(\mu_j - \mathbf{x}_i' \beta) - F(\mu_{j-1} - \mathbf{x}_i' \beta)] \quad (2.14)$$

Transformacja ta jest dopuszczalna, ponieważ funkcja logarytmiczna jest monotonicznie rosnąca, co oznacza, że maksimum funkcji  $L$  oraz  $\ln L$  przypada dla tych samych wartości parametrów. Postać addytywna (suma zamiast iloczynu) znacząco ułatwia obliczanie pochodnych

cząstkowych niezbędnych do wyznaczenia warunków pierwszego rzędu.

### 3.3 Procedury iteracyjne i optymalizacja numeryczna

W przypadku modelu *Ordered Logit* warunki konieczne istnienia ekstremum (*First Order Conditions*) prowadzą do układu równań nieliniowych względem parametrów  $\beta$  oraz  $\mu$ . W przeciwieństwie do regresji liniowej, nie istnieje tutaj rozwiązanie w postaci jawnego wzoru analitycznego (*closed-form solution*) (Maddala, 1983).

W związku z powyższym, szacowanie parametrów odbywa się przy użyciu numerycznych algorytmów iteracyjnych. Najczęściej wykorzystywaną metodą jest algorytm Newtona-Raphsona lub jego modyfikacje (np. metoda BFGS). Proces ten przebiega w kilku etapach:

1. *Inicjalizacja*: Przyjęcie początkowych wartości parametrów (często na podstawie uproszczonych modeli liniowych).
2. *Gradient i Hesjan*: Wyznaczenie wektora pochodnych cząstkowych (gradientu) oraz macierzy drugich pochodnych (macierzy informacyjnej/Hesjanu), która wskazuje kierunek i "stromość" wzrostu funkcji wiarygodności.
3. *Aktualizacja*: Korygowanie wartości parametrów w kierunku maksimum aż do momentu, gdy przyrost funkcji wiarygodności stanie się pomijalnie mały (osiągnięcie zbieżności).

Poprawność procesu estymacji w dużej mierze zależy od globalnej wklęsłości funkcji log-wiarygodności. Jak wskazuje J.M. Wooldridge, dla rozkładu logistycznego funkcja ta jest zazwyczaj dobrze uwarunkowana, co gwarantuje zbieżność algorytmów do globalnego maksimum, zapewniając stabilność uzyskanych wyników empirycznych (Jackowska, 2011). Osiągnięte w ten sposób oszacowania stanowią podstawę do dalszej interpretacji efektów krańcowych oraz weryfikacji istotności statystycznej badanych uwarunkowań opóźnień lotniczych.

## 4 Weryfikacja założeń i diagnostyka modelu

Proces budowy modelu ekonometrycznego nie kończy się na estymacji jego parametrów. Aby uzyskane wyniki mogły służyć do rzetelnego wnioskowania o przyczynach opóźnień lotniczych, konieczna jest rygorystyczna weryfikacja założeń statystycznych oraz ocena dobroci dopasowania modelu do danych empirycznych. W przypadku uporządkowanego modelu logistowego kluczowym punktem diagnostycznym jest sprawdzenie stabilności parametrów strukturalnych oraz weryfikacja siły predykcyjnej klasyfikatora.

### 4.1 Założenie o proporcjonalności szans (Parallel Regression Assumption)

Najbardziej krytycznym założeniem modelu *Ordered Logit* jest założenie o proporcjonalności szans, znane również jako założenie o równoległości regresji (*Parallel Regression Assumption*).

Jak wskazuje W. Greene (Greene, 2003), model ten zakłada, że wektor parametrów  $\beta$  pozostaje stały niezależnie od tego, przez który punkt odcięcia (próg  $\mu_j$ ) dokonujemy podziału zmiennej ukrytej.

Matematycznie oznacza to, że wpływ zmiennych objaśniających na logarytm szansy skumulowanej jest identyczny dla wszystkich kategorii:

$$\ln \left( \frac{P(y_i \leq j | \mathbf{x}_i)}{1 - P(y_i \leq j | \mathbf{x}_i)} \right) = \mu_j - \mathbf{x}_i' \beta \quad (2.15)$$

W powyższym równaniu indeks  $j$  występuje przy progu  $\mu$ , ale nie przy wektorze  $\beta$ . Oznacza to, że krzywe prawdopodobieństwa skumulowanego dla poszczególnych kategorii są względem siebie równoległe, a zmienia się jedynie ich przesunięcie określone przez progi  $\mu$ .

Weryfikacja tego założenia, najczęściej przeprowadzana za pomocą testu *Branta* lub testu ilorazu wiarygodności, jest niezbędna. Jego naruszenie sugeruje, że dana zmienna objaśniająca (np. siła wiatru lub specyfika linii lotniczej) może mieć zupełnie inny wpływ na prawdopodobieństwo wystąpienia małego opóźnienia, a inny na prawdopodobieństwo wystąpienia opóźnienia krytycznego. W sytuacji odrzucenia tego założenia, konieczne byłoby zastosowanie bardziej złożonych modeli, takich jak nieuporządkowany model wielomianowy (*Multinomial Logit*) lub uogólniony uporządkowany model logitowy (*Generalized Ordered Logit*), co jednak wiąże się ze znacznym wzrostem liczby parametrów i utratą przejrzystości interpretacyjnej (Maddala, 1983).

## 4.2 Kryteria informacyjne i miary dopasowania modelu

W ekonometrii modeli zmiennych jakościowych, gdzie nie jest możliwe zastosowanie klasycznego współczynnika determinacji  $R^2$  znanego z metody KMNK, do oceny jakości modelu wykorzystuje się miary oparte na wartości funkcji wiarygodności.

*Kryterium Informacyjne Akaike (AIC)* Kryterium AIC jest jednym z najpowszechniej stosowanych narzędzi do porównywania modeli o różnej liczbie zmiennych objaśniających. Jego wzór przyjmuje postać:

$$AIC = 2k - 2\ln(L) \quad (2.16)$$

gdzie  $k$  oznacza liczbę parametrów w modelu, a  $\ln(L)$  jest wartością zlogarytmowanej funkcji wiarygodności w punkcie optimum. Kluczową cechą AIC jest wprowadzenie kary za nadmierne rozbudowywanie modelu ( $2k$ ). Pozwala to uniknąć zjawiska przeuczenia (*overfitting*), promując modele, które osiągają wysoką wiarygodność przy zachowaniu oszczędności strukturalnej. Przy porównywaniu zestawu modeli, za najlepszy uznaje się ten, który charakteryzuje się najniższą wartością wskaźnika AIC (Greene, 2003).

*Pseudo R-kwadrat McFaddena* Inną ważną miarą diagnostyczną jest współczynnik *Pseudo R<sup>2</sup>*, wśród których najczęściej raportowany jest wskaźnik zaproponowany przez D. McFaddena. Informuje on o tym, o ile lepszy jest model z predyktorami w porównaniu do modelu bazowego

(zawierającego jedynie progi odcięcia). Oblicza się go według wzoru:

$$R_{McFadden}^2 = 1 - \frac{\ln(L_{full})}{\ln(L_{null})} \quad (2.17)$$

gdzie  $L_{full}$  to wiarygodność modelu pełnego, a  $L_{null}$  to wiarygodność modelu bez zmiennych objaśniających. Należy pamiętać, że w modelach logitowych wartości rzędu 0,2–0,4 są już uznawane za dowód bardzo dobrego dopasowania modelu do danych (Maddala, 1983), co stanowi istotną różnicę w porównaniu do interpretacji  $R^2$  w regresji liniowej.

### 4.3 Ewaluacja klasyfikacyjna i znaczenie metryk jakości

Współczesne podejście do diagnostyki modeli, silnie wspierane przez literaturę z zakresu uczenia maszynowego, kładzie duży nacisk na zdolność predykcyjną modelu. AlBassam i AlShahrani (AlBassam i AlShahrani, 2025) podkreślają, że w przypadku analizy opóźnień lotniczych – gdzie klasy są często niezbalansowane – same miary oparte na wiarygodności mogą być niewystarczające.

W związku z tym, uzupełnieniem diagnostyki ekonometrycznej jest analiza macierzy pomyłek oraz wyznaczenie wskaźników takich jak czułość (*recall*) i precyzja (*precision*). Pozwalają one ocenić, jak skutecznie model *Ordered Logit* radzi sobie z identyfikacją konkretnych kategorii opóźnień. Triangulacja miar ekonometrycznych (AIC, Pseudo  $R^2$ ) z miarami klasyfikacyjnymi zapewnia kompleksową ocenę rzetelności przeprowadzonego badania i pozwala na uniknięcie błędnych wniosków wynikających z asymetrii zbioru danych (AlBassam i AlShahrani, 2025; Jackowska, 2011).

## 5 Metryki predykcyjne i ocena jakości klasyfikatorów

Ostatnim etapem budowy fundamentu metodologicznego jest zdefiniowanie narzędzi pozwalających na ocenę zdolności predykcyjnej modelu. O ile miary oparte na wiarygodności (jak AIC czy Pseudo  $R^2$ ) informują o dopasowaniu statystycznym, o tyle metryki klasyfikacyjne pozwalają ocenić realną użyteczność modelu w przewidywaniu konkretnych stanów opóźnień. W obliczu masowego charakteru danych lotniczych, ocena ta musi uwzględniać fakt, iż poszczególne kategorie opóźnień występują z różną częstotliwością (AlBassam i AlShahrani, 2025).

### 5.1 Wieloklasowa macierz pomyłek (Confusion Matrix)

Podstawowym narzędziem diagnostycznym w procesie ewaluacji klasyfikatorów jest macierz pomyłek. Jest to zestawienie w formie tabelarycznej, które konfrontuje rzeczywiste przynależności obserwacji do poszczególnych klas z wynikami przewidywanymi przez model. Dla problemu o  $J$  kategoriach, macierz ta przyjmuje postać kwadratową o wymiarach  $J \times J$ .

Teoretyczne rozpisanie macierzy opiera się na czterech podstawowych komponentach, definiowanych w ujęciu „jeden kontra reszta” (*one-vs-all*) dla każdej kategorii  $j$ :

- *True Positive (TP)*: liczba przypadków, w których model poprawnie przewidział kategorię  $j$  (np. model trafnie wskazał duże opóźnienie).
- *True Negative (TN)*: liczba przypadków, w których model poprawnie wykluczył przynależność do kategorii  $j$ .
- *False Positive (FP)*: błąd pierwszego rodzaju; sytuacja, w której model błędnie przypisał obserwację do kategorii  $j$ , choć w rzeczywistości należała ona do innej klasy.
- *False Negative (FN)*: błąd drugiego rodzaju; sytuacja, w której model pominął obserwację faktycznie należącą do kategorii  $j$ .

Jak wskazują Hastie i in. (Hastie i in., 2009), analiza macierzy pomyłek pozwala na identyfikację konkretnych słabości modelu – na przykład tendencji do mylenia opóźnień średnich z dużymi, co jest kluczowe z punktu widzenia operacyjnego zarządzania ruchem lotniczym.

## 5.2 Wskaźniki jakości klasyfikacji

Na podstawie składowych macierzy pomyłek wyprowadza się zestaw wskaźników pozwalających na ilościową ocenę jakości predykcji. Najbardziej intuicyjną miarą jest ogólna trafność modelu (*Accuracy*), definiowana jako stosunek poprawnych diagnoz do wszystkich obserwacji:

$$Accuracy = \frac{\sum_{j=1}^J TP_j}{N} \quad (2.18)$$

gdzie  $N$  oznacza całkowitą liczebność próby. Należy jednak zaznaczyć, że miara ta bywa myląca w przypadku zbiorów asymetrycznych. Jeśli 80% lotów w próbie jest punktualnych, model ignorujący opóźnienia i zawsze przewidujący punktualność osiągnie pozornie wysoką trafność 80%, będąc jednocześnie bezużytecznym w prognozowaniu zakłóceń (AlBassam i AlShahrani, 2025).

Z tego względu konieczne jest wprowadzenie dwóch uzupełniających metryk:

1. *Precyzja (Precision)*: odsetek poprawnych przewidywań danej klasy wśród wszystkich przypadków, które model zaklasyfikował do tej klasy. Odpowiada na pytanie: jak dużą pewność mamy, że gdy model przewiduje duże opóźnienie, to ono faktycznie wystąpi?

$$Precision = \frac{TP}{TP + FP} \quad (2.19)$$

2. *Czułość (Recall / Sensitivity)*: zdolność modelu do wykrywania wszystkich przypadków należących do danej klasy. Odpowiada na pytanie: jaki odsetek faktycznych dużych opóźnień

nień został wykryty przez model?

$$Recall = \frac{TP}{TP + FN} \quad (2.20)$$

### 5.3 F1-Score jako optymalna miara dla zbiorów niezbalansowanych

W analizie opóźnień lotniczych badacz staje przed dylematem wyboru między wysoką precyzją a wysoką czułością. Rozwiązaniem tego problemu jest wskaźnik *F1-Score*, stanowiący średnią harmoniczną obu tych miar:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (2.21)$$

Zastosowanie średniej harmoniczej zamiast arytmetycznej powoduje, że *F1-Score* karze skrajnie niskie wartości jednego z komponentów. Model, który ma doskonałą czułość, ale fatalną precyzję, otrzyma niską notę końcową.

Współczesna literatura (AlBassam i AlShahrani, 2025; Hastie i in., 2009) uznaje *F1-Score* za optymalną metrykę w badaniach, gdzie występuje tzw. gruby ogon rozkładu lub znaczna dysproporcja klas. W badaniu punktualności lotów, gdzie priorytetem jest wykrywanie rzadszych, ale kosztownych „dużych opóźnień”, *F1-Score* pozwala na rzetelną ocenę, czy model rzeczywiście uczy się wzorców opóźnień, czy jedynie adaptuje się do dominującej klasy lotów punktualnych.

## Przejsie do części empirycznej

Zarysowany w niniejszym rozdziale aparat metodologiczny – obejmujący zarówno nieliniowe modele ekonometryczne, jak i zaawansowane metryki ewaluacyjne – stanowi kompletny zestaw narzędzi niezbędny do przeprowadzenia rzetelnego badania punktualności. Teoretyczne wyprowadzenie modelu *Ordered Logit* oraz zdefiniowanie mechaniki progów odcięcia pozwalają na przejście od rozważań czysto matematycznych do ich praktycznej implementacji.

W kolejnym rozdziale, stanowiącym wkład własny autora, powyższe metody zostaną wykorzystane do analizy rzeczywistych danych operacyjnych z amerykańskiego systemu transportowego. Wykorzystując bazę danych Departamentu Transportu (BTS) oraz zaawansowane pakiety statystyczne środowiska R, przeprowadzona zostanie estymacja parametrów modelu dla dziesięciu największych portów lotniczych w Stanach Zjednoczonych. Pozwoli to na weryfikację postawionych hipotez badawczych oraz próbę odpowiedzi na pytanie, w jakim stopniu czynniki pogodowe, infrastrukturalne i organizacyjne kształtują prawdopodobieństwo wystąpienia opóźnień w nowoczesnej sieci lotniczej.

# Bibliografia

- AlBassam, S. A. A., i AlShahrani, D. N. (2025). Flight delay prediction: Evaluating machine learning algorithms for enhanced accuracy. *PLoS One*, 20(12).
- Allain, V., i Ben Omrane, T. (2004). *Analysis of Low Cost Traffic Patterns* (EEC Note Nr EEC Note No. 06/04). EUROCONTROL Experimental Centre. Brétigny-sur-Orge, France.
- Diebold, F. X., i Schuermann, T. (1996). *Exact Maximum Likelihood Estimation of Observation-Driven Econometric Models* (Technical Working Paper Nr 194). National Bureau of Economic Research.
- Doganis, R. (2010). *Flying Off Course: Airline Economics and Marketing*. Routledge.
- EUROCONTROL. (2024). *CODA Digest: All-Causes Delay and Cancellations to Air Transport in Europe - Annual 2024* (Annual Report). European Organisation for the Safety of Air Navigation. Bruksela.
- Federal Aviation Administration. (2022). *The Economic Impact of Civil Aviation on the U.S. Economy* (Economic Impact Report). U.S. Department of Transportation. Washington, D.C.
- Greene, W. H. (2003). *Econometric Analysis* (5th). Prentice Hall.
- Hastie, T., Tibshirani, R., i Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2 wyd.). Springer Science; Business Media.
- International Air Transport Association. (2023). *Standard IATA Delay Codes (AHM 730)*. IATA. Montreal, Genewa.
- Jackowska, B. (2011). Efekty interakcji między zmiennymi objaśniającymi w modelu logitowym w analizie zróżnicowania ryzyka zgonu. *Przegląd Statystyczny*, 58(1-2), 117–133.
- Jetzki, M. (2009). The propagation of air transport delays in Europe. *Department of Airport and Air Transportation Research RWTH AACHEN UNIVERSITY*.
- Maddala, G. S. (1983). *Limited-Dependent and Qualitative Variables in Econometrics*. Cambridge University Press.

## Spis rysunków

|     |                                                                                            |    |
|-----|--------------------------------------------------------------------------------------------|----|
| 2.1 | Mechanika progów odcięcia i kategoryzacja zmiennej ukrytej w modelu Ordered Logit. . . . . | 16 |
|-----|--------------------------------------------------------------------------------------------|----|

## Spis tabel